

Project 1: 英文文本分类实验报告

姓名: 郭宇航 学号: 10234507018

github链接: <https://github.com/betterGuo/Contemporary-AI.git>

一、任务、数据与实验设置

本实验根据英文文本预测 0 至 9 的类别编号。我使用提供的 7,368 条有标签数据训练, 对 2,457 条无标签数据生成预测。检查发现没有缺失或空白文本, 训练集无精确重复行, 训练与测试文本无精确重叠; 各类约有 705 至 747 条, 文本长度中位数为 1,139 字符, 最长为 160,616 字符。我未删除、截断或改写原始数据, 也未给类别编号自行命名。

我先用 random_state=42 做分层 80%/20% 划分, 得到 5,894 条训练样本和 1,474 条验证样本。TF-IDF 只在训练折拟合, 再转换验证折, 避免信息泄漏。选模以 Macro-F1 为主, Accuracy 为辅; 分数相同时按预设候选次序选择。验证集参与调参, 其分数不是独立测试成绩。

实验在独立 Conda 环境 project1 中运行, 使用 Python 3.10.21、scikit-learn 1.7.2, 数值计算线程设为 1; 另建 project1_reproduce 环境完整复现。环境锁文件、参数、划分、逐类指标、预测和耗时均保留, 便于检查。

二、方法与基础模型比较

TF-IDF 降低常见词的权重, 突出区分文档的词。本实验使用 sublinear_tf=True, 词频为 $1 + \ln(\text{count})$, 平滑 IDF 为 $\ln((1+n)/(1+df))+1$, 最后做 L2 归一化。MultinomialNB 使用条件独立假设和加性平滑; Logistic Regression 使用交叉熵与 L2 正则; LinearSVC 使用 L2 正则和 squared-hinge 损失, 以 one-vs-rest 处理多类任务。本次用的是适合稀疏文本的 LinearSVC, 不是 LIBSVM 的线性核 SVC。

第一轮比较词表上限 {5000, 10000, 20000}、词 n-gram {(1,1), (1,2)}, 以及 NB 的 alpha={0.1, 0.5, 1}、LR 的 C={0.1, 1, 10}、LinearSVC 的 C={0.1, 1, 10, 100}, 共 60 组。LR/SVM 最大迭代次数分别为 2000/5000。所有候选运行成功, 无警告; 各模型最佳配置都采用 20k unigram。

模型及最佳参数	Accuracy	Macro-F1
MultinomialNB, alpha=0.1	0.9172	0.9180
Logistic Regression, C=10	0.9376	0.9377
LinearSVC, C=1	0.9403	0.9403

因此我选择 LinearSVC 继续优化, 不再增加模型种类。词袋不保留词序; 平均 Word2Vec 同样丢失词序, BERT 可利用位置和上下文, 但本实验未运行两者或 MLP。对 MLP 而言, 增加隐藏层或神经元会改变容量, 增加训练轮数只影响优化过程和时间, 不改变网络结构容量。

三、顺序优化与特征融合

第一步做受控局部搜索: 固定 unigram, 先比较词表 {20k, 40k, 80k, 不限}, 再在当步赢家上比较 min_df={1, 2, 3}, 最后比较 C={1, 0.5, 2}。重复配置复用, 共 8 个唯一候选, 不是全组合或全局最优搜索。词表增至 80k 时 Macro-F1 从 0.9403 升至 0.9456; 不限词表为 0.9450, min_df=2/3 为 0.9431/0.9410。最终选择 80k、min_df=1、C=0.5, Macro-F1 为 0.9458; C=2 为 0.9443。

第二步固定该词支路和 C, 加入字符支路: char_wb 3 至 5 gram、80k 特征、min_df=2。两路分别 L2 归一化, 按权重拼接后再次 L2 归一化, 仍由一个 LinearSVC 分类, 不是模型集成。除历史基线外, 下表候选均使用 C=0.5。

表示方式 (word:char 权重)	Accuracy	Macro-F1
优化 word-only	0.9457	0.9458
char-only	0.9356	0.9359
融合 1:0.25	0.9457	0.9458
融合 1:0.5	0.9478	0.9479
融合 1:1	0.9484	0.9486
融合 0.5:1	0.9410	0.9412

第三步先锁定配置，再在 seed 17、29、53、89、149 的五个分层划分上配对比较，不再调参。基线、优化词特征、字符特征、融合的 Macro-F1 均值分别为 0.9396、0.9440、0.9392、0.9480。融合对基线的五次提升均为正，配对差值均值为 +0.00832、样本标准差为 0.00333。这些划分共享样本，且 seed 42 已用于选模，因此仅说明切分敏感性，不作独立测试或显著性结论。

四、性能代价、错误分析与结论

我的改进重点是词与字符特征的互补，并用字符单支路 and 不同权重做消融，而不是堆叠模型。字符单独使用较弱，等权融合最好，支持两路互补的解释，但不能证明某种拼写机制带来了提升。相对优化词特征，融合仅多约 0.00283 Macro-F1，却把训练折 CSR 存储从 10.26 MiB 增至 120.14 MiB，冷路径耗时重建估计从 1.098 秒增至 12.659 秒。CSR 不是进程峰值内存，重建估计也不是独立墙钟计时。资源有限时，词级模型更合适。

seed 42 的错误数从 88 降至 76：纠正 24 条，新增 12 条。ID 2 的 F1 从 0.8649 升至 0.8725，ID 7 从 0.8759 升至 0.8966；但 7→2 的混淆仍有 11 条，未被解决。例如原始索引 3520 的 Conner CP3204F info please 从误判 7 改为正确的 2；索引 7351 的 Re: images of earth 则从正确的 0 变为错误的 5。这说明总体提高不代表每条样本都改善。

最终按预设规则选择等权融合，用全部有标签数据重新拟合，随后预测测试集。全量流程约 15.801 秒，包含向量化、组合、模型拟合及训练/测试预测。第二个独立环境结果一致，19 项核验全部通过。提交文件为 results_optimized/predictions.csv，按测试原顺序保存 2,457 个整数标签，无表头和索引；根目录同名文件保留旧基线，不能混用。由于测试集没有标签，我不报告测试准确率。我的结论是：受控特征融合确实改善了本次验证表现，但代价明显、仍存在类别混淆；创新价值应结合消融证据和课程标准评价，不保证加分。